UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE - UFRN
CENTRO DE ENSINO SUPERIOR DO SERIDÓ - CERES
DEPARTAMENTO DE COMPUTAÇÃO E TECNOLOGIA DCT

LUCAS DA COSTA SANTOS
Matrícula: 20250038952

AVALIAÇÃO COMPARATIVA DE MODELOS: SISTEMA ESPECIALISTA, ÁRVORE DE DECISÃO E ENSEMBLE LEARNING

Link do Dataset: https://www.kaggle.com/datasets/srisyra02/diabetes-risk-prediction-dataset
Repositório GitHub:
https://github.com/lucascsantos07/analise-comparativa-modelos-ia.git

Caicó - RN
2026

LUCAS DA COSTA SANTOS

AVALIAÇÃO COMPARATIVA DE MODELOS: SISTEMA ESPECIALISTA, ÁRVORE DE DECISÃO E ENSEMBLE LEARNING

Relatório de atividades apresentado como requisito para obtenção de nota na disciplina **Inteligência Artificial**, ofertada pela UFRN no período letivo 2026.2.

Professor: Prof. Dr. Thommas K. S. Flores

Universidade Federal do Rio Grande do Norte - UFRN
Centro de Ensino Superior do Seridó - CERES
Departamento de Computação e Tecnologia - DCT

Caicó - RN
2026

Índice

1 Introdução **4**

2 Protocolo experimental **4**
2.1 Ambiente computacional 5

3 Sistema especialista **6**
3.1 Base de conhecimento — classificação 6
3.2 Base de conhecimento — regressão 6
3.3 Motor de inferência e equivalência 7
3.4 Esforço humano (cronometragem) 8
3.5 Medição da inferência 8

4 Árvore de decisão **9**
4.1 Configuração e ajuste 9
4.2 Três regras extraídas e comparação com o especialista 9

5 Ensemble learning **10**
5.1 Curva de erro da Random Forest 11
5.2 Importância das features e comparação com as regras 11
5.3 Complexidade dos ensembles 12

6 Resultados de desempenho **13**
6.1 Classificação 13
6.2 Regressão 14

7 Generalização, viés e variância **15**
7.1 Diagnóstico e viés–variância 16

8 Eficiência computacional, energia e CO_2 **16**
8.1 Método de medição 16
8.2 Leitura dos custos 17
8.3 Implantação: edge versus servidor 18

9 Análise comparativa — perguntas (a)–(f) **18**

10 Vantagens, desvantagens e limitações **21**
10.1 Vantagens e desvantagens 21
10.2 Limitações do estudo 21

11 Considerações finais **22**
11.1 Referências 23

Lista de Figuras

1 Introdução

Este relatório tem como objetivo desenvolver e comparar diferentes abordagens de inteligência artificial para resolver problemas de regressão e classificação, utilizando o mesmo conjunto de dados. Serão estudados um sistema especialista, árvores de decisão e métodos de aprendizado em conjunto (*Ensemble Learning*), considerando o desempenho preditivo e a eficiência computacional de cada abordagem.

O conjunto de dados utilizado é o *Diabetes Risk Prediction Dataset*, obtido na plataforma Kaggle. Ele contém informações relacionadas a fatores que podem estar associados ao risco de diabetes, como glicemia em jejum, hemoglobina glicada, idade, índice de massa corporal, histórico familiar de diabetes, hipertensão e qualidade da alimentação. Essas informações são utilizadas como variáveis de entrada para o desenvolvimento dos modelos.

O problema de regressão tem como variável-alvo (*target*) o `Diabetes_Risk_Score`, que representa uma pontuação numérica de risco de diabetes. O objetivo é estimar essa pontuação a partir das características disponíveis no conjunto de dados.

Já o problema de classificação utiliza a variável-alvo `Diabetes_Risk`, que categoriza o risco de diabetes em três classes: *Low* (baixo), *Moderate* (moderado) e *High* (alto). Nesse caso, o objetivo é prever a categoria de risco correspondente às características de cada registro.

A partir desses dois problemas, serão implementados e avaliados os modelos propostos, utilizando métricas adequadas para regressão e classificação. Também serão analisados aspectos como capacidade de generalização, tempo de execução e consumo de memória, permitindo comparar os métodos de forma sistemática.

2 Protocolo experimental

Todos os modelos foram avaliados sob o mesmo protocolo, definido em `src/config.py` e reutilizado pelos *notebooks* 03 a 09. A divisão é 80/20 (40.000 treino e 10.000 teste), com `RANDOM_STATE = 42`; na classificação a divisão é estratificada. O conjunto de teste foi usado apenas na avaliação final. A seleção de hiperparâmetros usou validação cruzada de 5 *folds* sobre o treino (`GridSearchCV`), com `f1_macro` na classificação e `neg_root_mean_squared_erro` na regressão.

O pré-processamento é ajustado dentro de um `Pipeline` do scikit-learn, somente no treino de cada *fold*, evitando vazamento de dados. Para árvores e *ensembles*, as variáveis categóricas são codificadas em *one-hot* e as numéricas são mantidas sem padronização, pois árvores não exigem escala. O sistema especialista usa as variáveis brutas, com os limiares clínicos definidos na base de regras.

Na regressão, a busca otimizou RMSE, critério mais suave para o `GridSearchCV`; a comparação final usa MAE, que é mais interpretável e robusto a *outliers*. Como as duas métricas preservam a mesma ordem entre os modelos (Tabela 18), a diferença de critério não altera a recomendação.

Item	Configuração
Divisão treino/teste	80% / 20%; 40.000 / 10.000 registros
Semente	42 (divisão, modelos, amostragens e repetições)
Validação cruzada	5 *folds*, apenas no treino; `GridSearchCV`
Métrica principal — classificação	F1-*score* macro (justificativa: desbalanceamento)
Métrica principal — regressão	MAE (unidade do escore; robustez a *outliers*)
Métricas obrigatórias	Classificação: matriz de confusão, *accuracy*, *precision*, *recall*, F1, ROC-AUC, PR-AUC. Regressão: MAE, MSE, RMSE, MAPE, R^2, MedAE
Inferência	30 repetições, `time.perf_counter`; pico de memória com `tracemalloc`
Energia	Estimativa $P \times t$, com 65 W e 45,8 gCO_2/kWh

Tabela 1: Protocolo experimental comum.

2.1 Ambiente computacional

As medições foram feitas em um único computador. Como tempo e memória dependem do *hardware*, os valores servem para comparação relativa entre os modelos, não para extrapolação para outras máquinas.

Item	Valor
Processador	13th Gen Intel Core i5-13420H — 8 núcleos / 12 *threads*
Memória RAM	7,7 GB
Sistema operacional	Windows 11 (*build* 26200)
Python	3.14.3
pandas / NumPy	3.1.0 / 2.5.4
scikit-learn	1.9.1
matplotlib / seaborn	3.11.2 / 0.13.2
joblib	1.6.0

Tabela 2: Ambiente computacional.

A ordem de execução é 03 → 04 → 05 → 06 → 07 → 08 → 09. Os *notebooks* 04–09 consomem modelos e tabelas gerados pelos anteriores. O *notebook* 09 não treina nem reavalia nada: ele apenas integra as tabelas já produzidas, para que a análise final não introduza números novos.

3 Sistema especialista

3.1 Base de conhecimento — classificação

A base de classificação tem quatro regras, separadas entre diretrizes (limiares diagnósticos da *American Diabetes Association*) e heurísticas para a faixa intermediária. O motor faz encadeamento para frente: avalia todas as condições, coleta as regras ativadas e resolve conflitos por prioridade. A Tabela 3 apresenta a base completa.

Regra	**Tipo**	**Prior.**	**Condições (SE)**	**Conclusão (ENTÃO)**
R1	diretriz	1	Glicemia ≥ 126 **E** HbA1c $\geq 6{,}5$	High
R2	heurística	2	$80 \leq$ glicemia ≤ 125 **E** $5{,}3 \leq$ HbA1c $\leq 7{,}0$ **E** idade < 65	Moderate
R3	diretriz	3	Glicemia < 100 **E** HbA1c $< 5{,}7$	Low
R4	heurística	4	$80 \leq$ glicemia < 100 **E** $5{,}7 \leq$ HbA1c $< 6{,}5$	Moderate

Tabela 3: Base de regras de classificação (4 regras, 3 variáveis).

As regras R1 e R3 usam os mesmos pontos de corte em glicemia e HbA1c, o que garante rastreabilidade clínica. R2 e R4 preenchem a faixa intermediária. A base anterior tinha duas regras de risco alto (com e sem histórico familiar) com a mesma conclusão; elas foram fundidas em R1, pois a condição de histórico não mudava a saída. As previsões permaneceram idênticas, e a base passou de cinco para quatro regras.

No teste, o especialista cobriu 53,87% dos registros (5.387 de 10.000) e apresentou 45 conflitos, resolvidos pela prioridade. A *accuracy* nos casos cobertos foi 0,8766, mas o F1 macro foi 0,5618: o sistema acerta bem *High* (F1 0,9539), mas erra as fronteiras de *Moderate* e tem dificuldade com a classe rara *Low* (F1 0,2369). Os 46,13% restantes ficam como *Indeterminado* e não entram nas métricas — a cobertura é reportada separadamente para não maquiar o resultado.

O sistema não produz probabilidades: as regras afirmam uma classe, não uma frequência. Um escore ordinal (Low < Moderate < High) poderia ser construído para desenhar uma curva ROC, mas não seria uma probabilidade calibrada. Por isso, as curvas ROC e PR são apresentadas apenas para os modelos probabilísticos (árvore, Random Forest e Gradient Boosting).

3.2 Base de conhecimento — regressão

O alvo `Diabetes_Risk_Score` é contínuo (13 a 100; 86 valores distintos). Uma base finita de regras não consegue enumerar todos os valores possíveis. A solução adotada foi um **motor de pontuação aditiva**: cada regra representa uma faixa clinicamente interpretável e contribui com pontos para um escore, que é somado a uma pontuação base e truncado entre 0 e 100.

A versão 1 (v1) usava quatro células definidas pelas medianas de duas variáveis e só conseguia produzir quatro valores distintos; ela é mantida como linha de base. A versão 2 (v2) usa 19 regras de faixa e um escore aditivo, com pesos calibrados por regressão linear (OLS) **apenas no treino**. As faixas de referência (glicemia 100–125, HbA1c 5,7–6,5, IMC < 25 e idade 40–54) foram omitidas do desenho; o intercepto absorve a pontuação base e essas referências. Os coeficientes foram arredondados para inteiros, produzindo uma base auditável.

Variável	**Faixas e pontos**	**Regras**
Glicemia (mg/dL)	< 100: -10; 100–125: 0; ≥ 126: $+10$	3
HbA1c (%)	$< 5{,}7$: -9; 5,7–6,4: 0; $\geq 6{,}5$: $+9$	3
IMC (kg/m^2)	< 25: -5; 25–29,9: -2; 30–34,9: $+2$; ≥ 35: $+5$	4
Idade (anos)	< 40: -6; 40–54: -1; 55–69: $+3$; ≥ 70: $+4$	4
Histórico familiar	Sim: $+10$	1
Hipertensão	Sim: $+6$	1
Dieta	Ruim: $+6$	1
Atividade física	Baixa: $+6$; não informada: $+2$	2
Total	**Pontuação base 53; escore truncado em 0–100**	**19**

Tabela 4: Estrutura da base de regressão v2 (19 regras de faixa).

Exemplo de regra: `SE Fasting_Blood_Sugar` $\geq$ `126 ENTÃO PONTOS = +10` (tipo: diretriz). A inferência de um registro retorna o escore final e a lista de regras que contribuíram, permitindo mostrar ao paciente exatamente quais fatores somaram ou subtraíram pontos. No exemplo do *notebook* 03, um registro ativou regras que levaram o escore bruto a 98,0, mantido após o truncamento.

O intercepto da calibração OLS foi 46,921, compatível com a pontuação base 53 corrigida pelas faixas de referência de IMC (< 25: -5) e idade (40–54: -1): $53 - 5 - 1 = 47$. O R^2 do modelo linear de calibração no treino foi 0,7666, praticamente igual ao da base arredondada (0,7655 no teste). A perda de precisão pelo arredondamento é, portanto, desprezível. A v1 tinha MAE 11,2721 e R^2 0,1964 no teste; a v2 reduziu o MAE em 46,8% (para 5,9941) e elevou o R^2 para 0,7655.

3.3 Motor de inferência e equivalência

O motor simbólico é usado para explicar um registro individual; o motor vetorizado (atuando sobre uma matriz de ativação) é usado para avaliar milhares de registros com rapidez. Os dois caminhos foram comparados em 200 registros aleatórios do teste, com igualdade de conclusão, regra selecionada e regras ativadas. Essa equivalência permite medir o sistema especialista com o mesmo protocolo dos modelos de ML, sem abrir mão da auditabilidade por registro.

3.4 Esforço humano (cronometragem)

O tempo de elaboração foi registrado em `logs/cronometro_regras.csv`, com data, horário, interrupções e número de regras criadas. A Tabela 5 reproduz as sessões; a Tabela 6 resume os tempos.

Data	Sessão	Problema	Início–fim	Interrupções	Duração	Regras criadas
23/10/2026	1	Classificação	13:15:00–14:03:45	0	48 min 45 s	7
25/10/2026	2	Classificação	11:10:00–12:19:00	1	69 min 00 s	0
25/10/2026	3	Classificação	15:14:00–15:48:42	0	34 min 42 s	1
25/10/2026	4	Regressão	17:40:00–18:48:13	0	68 min 13 s	4

Tabela 5: Sessões de elaboração das regras (fonte: `logs/cronometro_regras.csv`).

Problema	Sessões	Regras cron.	Regras finais	Total (min)	Média/sessão (min)	Desvio (min)	Média/regra (min)
Classificação	3	8	4	152,45	50,82	17,24	19,06 (cronometrada); 38,11 (final)
Regressão	1	4	19	68,22	68,22	—	17,05 (cronometrada); —

Tabela 6: Resumo do esforço humano. A regressão está incompleta: 1 de 3 sessões e apenas a v1 foi cronometrada.

Pendência metodológica. O enunciado exige no mínimo três sessões por problema. A classificação está completa (três sessões; as oito regras cronometradas foram consolidadas em quatro, sem alterar previsões). A regressão tem apenas uma sessão, que elaborou a v1 (quatro regras por medianas); a v2 (19 faixas e calibração OLS) não foi cronometrada. Faltam **duas sessões adicionais de regressão**. Nenhum tempo foi inventado: o valor de 68,22 min é um **limite inferior** e se refere à v1.

3.5 Medição da inferência

Para o sistema especialista não há treinamento computacional: o conhecimento foi construído manualmente. A medição foi feita somente na inferência, com 30 repetições sobre o conjunto de teste (10.000 registros).

Problema	Regras	Tempo total (s)	Tempo/amostra (ms)	Vazão (amostras/s)	Pico RAM (MiB)	Tamanho (KiB)	Energia 1M (Wh)	CO_2 1M (g)
Classificação	4	0,0492	0,00492	203.132	2,10	0,79	0,0889	0,0041
Regressão (v2)	19	0,0528	0,00528	189.318	2,10	1,95	0,0954	0,0044

Tabela 7: Inferência do sistema especialista (30 repetições; energia estimada).

O tempo por amostra é da ordem de microssegundos e o artefato ocupa menos de 2 KiB. O pico de memória inclui o *DataFrame* de saída com a lista de regras ativadas, não apenas a base de regras. Essas características viabilizam execução em dispositivos embarcados e explicam por que o custo dominante do especialista é humano, não computacional.

4 Árvore de decisão

4.1 Configuração e ajuste

Foram treinadas árvores de referência sem restrição (Gini e entropia na classificação; MSE e MAE na regressão) e, em seguida, árvores ajustadas por busca em grade com 60 combinações e validação cruzada de 5 *folds*. Os hiperparâmetros de complexidade considerados foram `max_depth`, `min_samples_leaf` e `ccp_alpha` (poda por custo-complexidade).

Problema	**Critério**	**Profundidade**	**Mín. folha**	`ccp_alpha`	**CV (métrica)**
Classificação	entropia	10	10	0,0	F1 macro 0,6781
Regressão	`squared_error` (MSE)	10	20	0,0005	RMSE 7,9661

Tabela 8: Hiperparâmetros escolhidos pela validação cruzada.

As árvores sem poda crescem até separar quase perfeitamente o treino: a árvore Gini atinge F1 de treino 1,0 e profundidade 25 (10.355 nós e 5.178 folhas), mas F1 de teste 0,5843. Na regressão, a árvore MSE sem poda atinge MAE de treino 0,0 e profundidade 35. A poda reduz drasticamente a complexidade e melhora o teste.

Modelo	**Profundidade**	**Nós**	**Folhas**	**Métrica de teste**	**Valor**
Classificação — Gini sem poda	25	10.355	5.178	F1 macro	0,5843
Classificação — entropia sem poda	—	—	—	F1 macro	0,6216
Classificação — ajustada	10	1.469	735	F1 macro	0,6649
Regressão — MSE sem poda	35	69.915	34.958	MAE	8,6818
Regressão — ajustada	10	1.583	792	MAE	6,2824

Tabela 9: Efeito da poda: complexidade e desempenho no teste.

$\text{arvore}_{d}ecisao_{p}rimeiros_{n}iveis.pngPrimeirosnveisdarvoredeclassificaoajustada(profundidaden$

4.2 Três regras extraídas e comparação com o especialista

Foram extraídas três folhas reais da árvore de classificação. A probabilidade é a proporção da classe na folha e o número de amostras é o suporte no treino.

ARV1 (High). Converge com a regra R1 do especialista nos dois marcadores centrais (glicemia $> 125{,}95$ e HbA1c $> 6{,}45$, praticamente os limiares 126 e 6,5). A árvore acrescenta histórico familiar, idade e hipertensão para isolar um subgrupo de 1.958 pacientes com pureza total. A regra do especialista é mais simples e mais geral: ela afirma High apenas com os dois critérios diagnósticos. A árvore mostra que, nesse subgrupo, os critérios adicionais aumentam a confiança, mas não são necessários para a conclusão clínica.

Regra	Classe	Prob.	Amostras	Condições
ARV1	High	1,000	1.958	Glicemia $>$ 125,95 **E** HbA1c $>$ 6,45 **E** histórico familiar = Sim **E** idade $>$ 59,5 **E** hipertensão $\neq$ Não
ARV2	Low	0,622	37	Glicemia $\leq$ 99,95 **E** HbA1c $\leq$ 5,65 **E** histórico $\neq$ Sim **E** idade $\leq$ 63,5 **E** IMC $>$ 30,55 **E** dieta $\neq$ Ruim **E** PCOS = Não **E** hipertensão $\neq$ Sim
ARV3	Moderate	0,743	175	Glicemia $>$ 125,95 **E** HbA1c $>$ 6,45 **E** histórico $\neq$ Sim **E** idade $\leq$ 44,5 **E** IMC $\leq$ 29,95 **E** doença cardíaca $\neq$ Sim **E** PCOS $\neq$ Sim **E** hipertensão $\neq$ Sim **E** dieta $\neq$ Ruim

Tabela 10: Regras ARV1–ARV3 extraídas da árvore de classificação.

ARV2 (Low). Também converge com R3 nos marcadores (glicemia $\leq$ 99,95 e HbA1c $\leq$ 5,65), mas acrescenta seis condições (IMC, idade, histórico, dieta, PCOS e hipertensão) e tem suporte de apenas 37 amostras. É uma regra instável: pequenas mudanças nos dados podem alterar seus cortes. O especialista prefere a versão simples e auditável.

ARV3 (Moderate) — o caso mais informativo. A regra tem glicemia e HbA1c acima dos limiares diagnósticos, mas conclui *Moderate* porque o paciente não tem histórico familiar, é jovem ($\leq$ 44,5), tem IMC $\leq$ 29,95 e não tem comorbidades. Pela regra R1 do especialista, esse paciente seria *High*. A árvore está descrevendo uma exceção aprendida nos dados (175 amostras, 74,3% Moderate), não uma diretriz clínica. Esse é o ponto central da comparação: a árvore captura idiossincrasias e interações do *dataset*, enquanto o especialista codifica conhecimento clínico generalizável. Para auditoria e segurança, a regra do especialista é mais defensável; para desempenho preditivo, a árvore pode explorar padrões que a regra não prevê — desde que validados externamente.

As três regras também evidenciam o *trade-off* de interpretabilidade: a árvore é legível nos primeiros níveis, mas as folhas já combinam até nove condições; a árvore completa tem 735 folhas. O especialista inteiro tem quatro regras e três variáveis.

5 Ensemble learning

Foram treinados Random Forest (obrigatório) e Gradient Boosting (segundo método), com ajuste de hiperparâmetros por validação cruzada. A Random Forest combina árvores independentes em amostras *bootstrap* e reduz a variância pela média; o Gradient Boosting constrói árvores sequenciais, cada uma corrigindo o erro residual das anteriores, e reduz o viés.

Modelo	n_estimators	max_depth	max_features	min_samples_leaf	learning_rate	CV (métrica)
RF — classificação	100	ilimitado	0,5	1	—	F1 macro 0,6838
GB — classificação	200	3	—	—	0,1	F1 macro 0,7126
RF — regressão	200	ilimitado	0,5	5	—	RMSE 7,6404
GB — regressão	200	2	—	—	0,1	RMSE 7,3797

Tabela 11: Hiperparâmetros escolhidos para os *ensembles*.

5.1 Curva de erro da Random Forest

A curva abaixo varia o número de árvores de 1 a 200. Com poucas árvores o erro de teste é alto e instável; a partir de algumas dezenas ele se estabiliza. O erro de treino cai para zero, o que é esperado em árvores profundas.

Árvores	Erro treino (classe)	Erro teste (classe)	MAE treino (reg.)	MAE teste (reg.)
1	0,0683	0,1890	3,1734	8,6542
10	0,0101	0,1425	2,5604	6,5331
50	0,0004	0,1327	2,3581	6,3633
100	0,000025	0,1317	2,3305	6,3301
200	0,0000	0,1326	2,3182	6,3177

Tabela 12: Curva de erro da Random Forest em função do número de árvores.

fig02-curva-rf.pngErro de treino e teste da Random Forest para classificação e regressão.fig:curva-rf

A leitura é a clássica de *bagging*: mais árvores reduzem a variância da previsão média, mas não corrigem o viés de árvores profundas. O erro de teste praticamente não melhora de 50 para 200 árvores (13,27% → 13,26%; MAE 6,36 → 6,32), enquanto o custo de memória cresce linearmente. O patamar elevado de erro de teste, apesar do erro de treino nulo, é o retrato do *overfitting* que aparecerá na análise de generalização.

5.2 Importância das features e comparação com as regras

A importância por impureza é global: ela indica quanto cada variável contribuiu para as divisões, não explica uma previsão individual. A Tabela 13 e a Figura **??** comparam Random Forest e Gradient Boosting nos dois problemas.

fig03-importancia.pngImportância das *features* nos quatro modelos (saída do *notebook* 05).fig:importancia

Classificação. As regras do especialista usam glicemia (1ª no RF, 0,302), HbA1c (2ª, 0,204) e idade (4ª, 0,148). Ficam de fora o IMC (3ª, 0,154) e o histórico familiar (5ª no RF, 0,052; 3ª no GB, 0,106). Isso explica parte do *gap* de desempenho: os *ensembles* capturam sinal em variáveis que a base não usa. A consistência entre RF e GB (glicemia e HbA1c sempre no topo) mostra que os fatores dominantes são os mesmos; a diferença

Feature	RF classificação	GB classificação	RF regressão	GB regressão
Fasting_Blood_Sugar	**0,302**	**0,369**	**0,344**	**0,355**
HbA1c	0,204	0,234	0,216	0,217
BMI	0,154	0,074	0,100	0,082
Age	0,148	0,104	0,116	0,107
Family_History_Diabetes	0,052	0,106	0,109	0,120
Diet_Quality	0,047	0,031	0,036	0,037
Hypertension	0,032	0,032	0,039	0,044
Heart_Disease	0,031	0,026	—	—
PCOS	0,030	0,025	—	—
Physical_Activity_Level	—	—	0,038	0,038

Tabela 13: Importância das *features* por impureza (média das árvores).

está nas interações e nos limiares finos.

Regressão. As oito variáveis das regras cobrem todo o conjunto e as cinco primeiras importâncias (glicemia, HbA1c, idade, histórico e IMC) são justamente as mais usadas. A base v2 está bem alinhada com o modelo, embora a estrutura aditiva não capture interações — o que ajuda a explicar por que o GB ainda é ligeiramente melhor.

Ressalva. A importância por impureza é global, favorece variáveis contínuas e não substitui SHAP ou *permutation importance* (não realizados). As conclusões sobre explicabilidade são, portanto, qualitativas.

5.3 Complexidade dos ensembles

Modelo	Árvores	Nós totais	Profundidade máxima
RF — classificação	100	823.112	29
GB — classificação	600	9.000	3
RF — regressão	200	1.592.532	28
GB — regressão	200	1.400	2

Tabela 14: Complexidade dos *ensembles*. O GB de classificação tem 600 árvores porque são 200 estimadores $\times$ 3 classes.

A diferença de complexidade é decisiva para o tamanho em disco e para a latência. A Random Forest guarda centenas de milhares de nós profundos; o Gradient Boosting guarda poucas árvores rasas. Isso explica por que o GB entrega desempenho semelhante com um artefato ordens de grandeza menor.

6 Resultados de desempenho

6.1 Classificação

A Tabela 15 apresenta as métricas no teste completo. O especialista é avaliado apenas nos 53,87% de registros que consegue classificar; a cobertura aparece na última coluna e a comparação no subconjunto comum é feita na Tabela 16.

Modelo	Acc.	Prec. macro	Rec. macro	F1 macro	F1 weighted	F1 High	ROC-AUC	PR-AUC	Cob.
Especialista	0,8766	0,5760	0,6789	0,5618	0,8794	0,9539	—	—	53,87%
Árvore de Decisão	0,8595	0,7036	0,6393	0,6649	0,8569	0,9119	0,8871	0,6634	100%
Random Forest	0,8678	0,7786	0,6460	0,6862	0,8655	0,9160	0,9414	0,7418	100%
Gradient Boosting	0,8790	0,7540	0,6326	0,6681	0,8760	0,9245	0,9591	0,7720	100%

Tabela 15: Métricas de classificação no teste (10.000 registros; especialista em 5.387 cobertos).

Modelo	Accuracy	F1 macro	F1 High
Especialista	0,8766	0,5618	0,9539
Árvore de Decisão	0,9244	0,7018	0,9632
Random Forest	0,9244	0,7310	0,9610
Gradient Boosting	0,9304	0,7124	0,9654

Tabela 16: Comparação no subconjunto comum (apenas registros classificados pelo especialista).

Classe	Especialista	Árvore	Random Forest	Gradient Boosting
Low (suporte 94)	0,237	0,364	0,403	0,321
Moderate (suporte 2.587)	0,495	0,719	0,739	0,759
High (suporte 7.319)	0,954	0,912	0,916	0,924

Tabela 17: F1-*score* por classe no teste completo (suporte total; o especialista é avaliado apenas nos casos cobertos).

Leitura. A *accuracy* é enganosa: o especialista tem 0,8766, próximo dos *ensembles*, mas só responde a 53,87% dos casos e tem F1 macro 0,5618. No subconjunto comum, os modelos de ML continuam à frente (RF 0,7310; GB 0,7124; árvore 0,7018), mostrando que a diferença não é apenas cobertura. O especialista, porém, tem o melhor F1 de High (0,9539), a classe de maior custo clínico; seu ponto fraco é Moderate (0,495) e a classe rara Low (0,237).

A classe Low tem menos de 1% do teste; o F1 macro é sensível a esses poucos casos. O Gradient Boosting tem a melhor *accuracy* e o melhor ROC-AUC/PR-AUC; a Random Forest tem o melhor F1 macro em uma única divisão, mas a diferença para o GB (0,0181)

é menor que um desvio padrão da CV. A escolha entre os dois não deve ser feita por essa diferença isolada.

fig04-confusao.pngMatrizes de confusão no teste (especialista, árvore, Random Forest e Gradient Boosting). A matriz do especialista cobre apenas 5.387 registros.fig:confusao

fig05-roc-pr.pngCurvas ROC e *Precision-Recall* dos modelos probabilísticos (árvore, RF e GB).fig:roc-pr

As curvas ROC e PR confirmam a hierarquia: o Gradient Boosting tem a maior área (ROC-AUC 0,9591; PR-AUC 0,7720), seguido da Random Forest (0,9414; 0,7418) e da árvore (0,8871; 0,6634). O especialista não aparece porque não produz probabilidades calibradas. As probabilidades das árvores e *ensembles* também não foram calibradas (Platt/isotônica); os valores de AUC medem a ordenação, não a confiança absoluta.

6.2 Regressão

Modelo	**MAE**	**MSE**	**RMSE**	**MAPE (%)**	R^2	**MedAE**
Especialista v1 (4 células)	11,2721	194,0894	13,9316	17,15	0,1964	9,6733
Especialista v2 (19 faixas)	5,9941	56,6337	7,5255	8,77	0,7655	5,0000
Árvore de Decisão	6,2824	62,0958	7,8801	9,22	0,7429	5,2752
Random Forest	6,1402	58,7201	7,6629	8,99	0,7569	5,2245
Gradient Boosting	**5,9278**	**54,4626**	**7,3799**	**8,65**	**0,7745**	5,0677

Tabela 18: Métricas de regressão no teste (10.000 registros).

fig06-reg-previsto-real.pngResíduos e valores previstos versus reais para os modelos de regressão.fig:reg

Leitura. O Gradient Boosting tem o menor MAE (5,9278) e o maior R^2 (0,7745); o especialista v2 vem logo atrás (5,9941; 0,7655). A v1 é claramente inadequada (MAE 11,2721; R^2 0,1964) e serve apenas como linha de base: quatro valores distintos não conseguem representar um alvo contínuo. A árvore e a Random Forest ficam no meio, com R^2 0,7429 e 0,7569.

O MAE é a métrica principal porque está na unidade do escore e é robusto a *outliers*; o RMSE (que penaliza mais os erros grandes) mantém a mesma ordem. A razão RMSE/MAE é semelhante entre os modelos ($\approx$ 1,24–1,25), indicando que nenhum deles é dominado por poucos erros extremos. O MAPE de 8,65–9,22% nos modelos de ML e 8,77% no especialista v2 é coerente com essa leitura. O MedAE de aproximadamente 5 pontos reflete a granularidade do alvo e é dominado por muitos erros pequenos.

Os resíduos do especialista v2 mostram um padrão ligeiramente discreto, esperado de uma soma de faixas; os do GB são mais dispersos, mas com menor erro absoluto médio. A Random Forest apresenta maior dispersão e um viés visível nos extremos, consistente com o *overfitting* detectado adiante.

7 Generalização, viés e variância

O *gap* de generalização é a diferença entre o desempenho no treino e no teste. Para métricas de erro, o sinal é invertido: um *gap* positivo de MAE (teste − treino) indica piora. A validação cruzada de 5 *folds* complementa a leitura, pois reduz a dependência de uma única divisão.

Modelo	**F1 treino**	**F1 teste**	**Gap F1**	**Cobertura**
Especialista	0,5688	0,5618	**0,0070**	53,87%
Árvore de Decisão	0,7473	0,6649	0,0823	100%
Random Forest	0,99998	0,6862	0,3138	100%
Gradient Boosting	0,7506	0,6681	0,0826	100%

Tabela 19: *Gap* de generalização na classificação (F1 macro).

Modelo	**MAE treino**	**MAE teste**	**Gap MAE**	R^2 **treino**	R^2 **teste**	**Gap** R^2
Especialista v1	11,2458	11,2721	0,0263	0,2054	0,1964	0,0089
Especialista v2	5,9903	5,9941	**0,0039**	0,7667	0,7655	**0,0012**
Árvore de Decisão	5,8279	6,2824	0,4545	0,7813	0,7429	0,0384
Random Forest	4,5915	6,1402	1,5487	0,8626	0,7569	0,1057
Gradient Boosting	5,8817	5,9278	0,0461	0,7794	0,7745	0,0049

Tabela 20: *Gaps* de generalização na regressão.

Modelo	**CV 5-fold (classificação)**	**CV 5-fold (regressão)**
Especialista	0,5687 ± 0,0122	5,9903 ± 0,0413 (v2)
Árvore de Decisão	0,6781 ± 0,0300	6,3585 ± 0,0355
Random Forest	0,6838 ± 0,0247	6,1172 ± 0,0407
Gradient Boosting	**0,7126 ± 0,0200**	**5,9188 ± 0,0316**

Tabela 21: Validação cruzada de 5 *folds* no treino (F1 macro e MAE).

fig07-gap.png*Gap* treino→teste por modelo nos dois problemas.fig:gap

Classificação. A Random Forest é o caso clássico de *overfitting*: F1 de treino praticamente 1,0 contra 0,6862 no teste (*gap* 0,3138). A árvore e o Gradient Boosting têm *gaps* quase idênticos (0,0823 e 0,0826) e desempenho de teste semelhante. O especialista tem o menor *gap* (0,0070), mas isso reflete uma base fixa, não aprendizado: o F1 de treino e teste é o mesmo por construção, e a CV é calculada apenas na parte coberta. Entre os modelos que aprendem, o GB leva vantagem por ter a melhor média de CV (0,7126) e menor desvio (0,0200).

Há uma inversão interessante entre teste e CV: o GB tem F1 0,6681 no teste, mas 0,7126 na CV (diferença de −0,0445, ≈ 2,2 desvios padrão). A Random Forest tem 0,6862

no teste e 0,6838 na CV. Isso mostra que a única divisão favoreceu a RF e desfavoreceu o GB; a CV é mais confiável para escolher o modelo, e nela o GB é claramente superior.

Regressão. O especialista v2 tem o menor *gap* de MAE (0,0039) e de R^2 (0,0012), seguido de perto pelo Gradient Boosting (0,0461; 0,0049). A árvore (0,4545) e a Random Forest (1,5487) pioram muito do treino para o teste; a RF é a que mais decora (R^2 de treino 0,8626 contra 0,7569 no teste). Em termos de generalização absoluta, o GB é o melhor compromisso: *gap* pequeno e o melhor erro de teste. O especialista v2 é o mais estável, mas seu erro é ligeiramente maior.

7.1 Diagnóstico e viés–variância

- **Especialista:** alto viés e variância nula. Os limiares são fixos e usam apenas três variáveis na classificação; o modelo não aprende dos dados. Isso explica o F1 macro baixo e a cobertura de 53,87%, mas também a estabilidade perfeita entre treino e teste.
- **Árvore:** variância controlada por profundidade, folha mínima e poda. Sem poda, a profundidade 25–35 e o erro de treino nulo produzem *overfitting* severo (F1 de teste 0,58–0,62; MAE 8,68). A versão podada reduz o *gap* para 0,0823 (classificação) e 0,4545 (regressão) e é a melhor opção interpretável entre os modelos que aprendem.
- **Random Forest:** o *bagging* deveria reduzir a variância, mas as árvores são muito profundas (profundidade 28–29; folha mínima 1–5) e a média ainda memoriza o treino. O *gap* de 0,3138 (classificação) e 1,5487 (regressão) mostra que a variância não foi controlada. Aumentar o número de árvores estabiliza a curva, mas não corrige o viés nem o *overfitting*.
- **Gradient Boosting:** árvores rasas (profundidade 2–3) e taxa de aprendizado 0,1 reduzem o viés sequencialmente com variância controlada. É o melhor equilíbrio: melhor CV nos dois problemas, *gap* pequeno e erro de teste baixo. É, porém, o mais sensível a hiperparâmetros e o mais caro de treinar na classificação (30,34 s).

8 Eficiência computacional, energia e CO_2

8.1 Método de medição

Tempo de treinamento: `time.perf_counter` em torno do *refit* final, em uma única execução. Tempo de inferência: 30 repetições sobre os 10.000 registros de teste; reporta-se a média e o desvio entre repetições. Memória: pico com `tracemalloc`, medido em uma passagem separada para não distorcer o *wall-clock*. Tamanho: arquivo serializado em disco (`joblib` para ML; `pickle` para as regras). Energia: estimativa $\texttt{P} \times \texttt{t}$ com potência média de 65 W e fator de emissão de 45,8 gCO_2/kWh (fator apresentado na disciplina). Não foi usado medidor de parede nem o *codecarbon*; os valores servem para comparação relativa.

Limite da comparação. Os tempos de ML são de *refit* do modelo final e **não incluem a busca de hiperparâmetros**. O custo real de construção dos modelos é, portanto, maior que o reportado. Na classificação, o Gradient Boosting tem 600 árvores (200 estimadores × 3 classes), o que explica seu tempo de 30,34 s.

Modelo	Treino (s)	RAM treino (MiB)	Inf. (ms/amostra)	Vazão (amostras/s)	RAM inf. (MiB)	Tamanho	Energia treino (Wh)	Energia 1M (Wh)	Esforço humano (min)
Esp. classificação	—	—	0,00492	203.132	2,10	0,79 KiB	—	0,0889	152,45
Árvore classificação	0,320	9,19	**0,00195**	512.885	2,69	130,83 KiB	0,0058	0,0352	—
RF classificação	1,005	33,80	0,00968	103.254	5,67	69,1 MiB	0,0182	0,1749	—
GB classificação	30,339	12,33	0,00883	113.197	2,98	774,52 KiB	0,5478	0,1595	—
Esp. regressão (v2)	—	—	0,00528	189.318	2,10	1,95 KiB	—	0,0954	68,22*
Árvore regressão	0,133	9,19	**0,00140**	713.539	2,69	115,44 KiB	0,0024	0,0253	—
RF regressão	1,551	25,91	0,01599	62.537	3,81	109,4 MiB	0,0280	0,2887	—
GB regressão	6,268	9,19	0,00309	323.114	2,69	157,02 KiB	0,1132	0,0559	—

Tabela 22: Eficiência computacional. *O esforço de 68,22 min refere-se à v1; a v2 não foi cronometrada. Energia é estimativa.

fig08-tempo-memoria.pngTempo e memória/tamanho por modelo (*notebook* 08).fig:tempo-mem

fig09-energia-tradeoff.pngEnergia/CO_2 e *trade-off* final entre desempenho e custo.fig:energia

8.2 Leitura dos custos

Treinamento. A árvore é a mais barata (0,320 s na classificação e 0,133 s na regressão). A Random Forest treina rápido (1,005 s e 1,551 s) porque paraleliza as árvores, mas paga em tamanho. O Gradient Boosting é sequencial e o mais caro na classificação (30,339 s); na regressão são 6,268 s. O GB de classificação é cerca de 30× mais lento que a RF para treinar, mas 91× menor em disco.

Inferência. A árvore é a mais rápida nos dois problemas (0,00195 ms/amostra na classificação e 0,00140 ms na regressão). Na classificação, a ordem é árvore < especialista (0,00492) < GB (0,00883) < RF (0,00968). Na regressão, é árvore < GB (0,00309) < especialista (0,00528) < RF (0,01599). Em lote de 10.000 registros, isso significa dezenas a centenas de milissegundos — irrelevante para a maioria das aplicações, mas relevante em altíssima frequência.

Memória e tamanho. O especialista é o menor artefato: 0,79 KiB (classificação) e 1,95 KiB (regressão). A árvore fica em 131/115 KiB; o GB em 775/157 KiB. A Random Forest é cerca de **91× maior que o GB** na classificação e **714× maior** na regressão (69,1 MiB e 109,4 MiB), porque guarda 100/200 árvores profundas (823 mil e 1,59 milhão de nós). O GB de classificação é cerca de 975× maior que o especialista; o de regressão, cerca de 80×.

Energia. O treinamento do GB consome 0,548 Wh (classificação) e 0,113 Wh (regressão) — valores absolutos desprezíveis. A inferência de 1 milhão de registros custa entre 0,025 e 0,289 Wh e emite no máximo 0,013 g de CO_2. Como a árvore e a RF treinam em frações de segundo, essa inferência equivale a 6,1–10,5× a energia de treino delas. No GB, a relação é de 29% (classificação) e 49% (regressão). Em outras palavras, o treinamento do GB é caro em relação à sua própria inferência, mas continua sendo energeticamente trivial.

Trade-off. Existe, mas não é linear. Na classificação, a RF troca ∼91× o tamanho

do GB por um ganho de F1 que não é claro; o GB entrega quase o mesmo desempenho com 1/91 do tamanho e melhor CV. Na regressão, o GB é ao mesmo tempo o melhor e um dos menores; a RF é a pior combinação (maior, mais lenta, com *overfitting*). O especialista v2 é o menor e muito competitivo, mas exige manutenção manual.

8.3 Implantação: edge versus servidor

Edge. O especialista é o candidato natural: menos de 2 KiB, sem dependência de biblioteca de ML e inferência em microssegundos. A árvore também é viável (≈ 115–131 KiB) e é a mais rápida, mas exige o *runtime* do scikit-learn. O GB cabe em dispositivos com pouca memória (157–775 KiB), embora a inferência seja mais lenta que a da árvore. A Random Forest é problemática em dispositivos restritos: 69,1 MiB (classificação) e 109,4 MiB (regressão) de artefato, além de 3,8–5,7 MiB de pico de inferência medido; isso pode inviabilizar microcontroladores e exigir pelo menos centenas de megabytes livres.

Servidor. O GB é preferível: melhor desempenho, artefato compacto, baixa latência e custo de treinamento aceitável. A RF não traz ganho que justifique o consumo de memória. O especialista continua útil como camada de validação e auditoria, especialmente para explicar decisões e detectar entradas fora do domínio das regras.

9 Análise comparativa — perguntas (a)–(f)

(a) Qual modelo teve o melhor desempenho no teste? A diferença é relevante?

Classificação. A Random Forest teve o maior F1 macro (0,6862), contra 0,6681 do Gradient Boosting, 0,6649 da árvore e 0,5618 do especialista. A diferença RF − GB é 0,0181, cerca de 0,6 desvio padrão combinado da CV (0,0318), portanto não é uma diferença clara. A CV conta outra história: o GB tem a melhor média (0,7126 ± 0,0200) contra 0,6838 ± 0,0247 da RF. O RF ganha por pouco em uma única divisão, mas o GB é mais consistente entre *folds* e tem a melhor *accuracy* (0,8790) e o melhor ROC-AUC/PR-AUC.

Regressão. O Gradient Boosting teve o menor MAE (5,9278) e o maior R^2 (0,7745). A diferença para o especialista v2 (5,9941; 0,7655) é 0,0663, cerca de 1,3 desvio padrão combinado (0,0520) — pequena, mas consistente, pois o GB também lidera na CV (5,9188 ± 0,0316 contra 5,9903 ± 0,0413). A vantagem sobre a RF (6,1402) e a árvore (6,2824) é maior (4,1 e 7,5 desvios combinados). A v1 (11,2721) é inadequada.

(b) Qual modelo generaliza melhor?

Classificação. O especialista tem o menor *gap* (0,0070), mas é uma base fixa e cobre só 53,87%; isso não é generalização aprendida. Entre os modelos que aprendem, a árvore e o GB têm *gaps* praticamente iguais (0,0823 e 0,0826) e o GB tem a melhor CV. A

Random Forest *overfitta* (*gap* 0,3138). O GB é, portanto, o melhor compromisso entre *gap* e desempenho absoluto.

Regressão. O especialista v2 é o mais estável (*gap* de MAE 0,0039), seguido do GB (0,0461). A árvore (0,4545) e a RF (1,5487) pioram muito. Em generalização absoluta, o GB é o melhor: *gap* pequeno e menor erro de teste. O especialista v2 é o mais estável, mas com erro ligeiramente maior.

(c) Qual modelo é mais eficiente? Existe *trade-off*?

O especialista é o mais eficiente em tamanho (0,8–2 KiB), memória e custo de inferência; a árvore é a mais rápida em latência e treina em frações de segundo. O GB é o melhor equilíbrio para produção: artefato compacto (157–775 KiB), inferência rápida (0,0031–0,0088 ms/amostra) e melhor desempenho. A RF é a menos eficiente: 69,1–109,4 MiB, inferência 1,1–5,2× mais lenta que o GB e treinamento que não compensa o ganho. Existe *trade-off* claro entre desempenho e custo, mas ele não é monotônico: o GB domina a RF nos dois problemas, e o especialista só perde em desempenho, não em custo.

(d) Qual o custo de construção do especialista versus o treinamento de ML?

O esforço humano medido foi 152,45 min na classificação (2,54 h, três sessões) e 68,22 min na regressão (1,14 h, uma sessão, apenas v1). O *refit* dos três modelos de ML somou 31,66 s (0,53 min) na classificação e 7,95 s (0,13 min) na regressão. As razões são ∼289× (classificação; ∼301× contra o GB isolado) e ∼515× (regressão; ∼653× contra o GB).

Essas razões são limites superiores da vantagem humana, porque a busca de hiperparâmetros não foi cronometrada: o custo real de ML é maior. Mesmo que a busca multiplicasse o custo de ML por 100, o total ficaria em ∼53 min na classificação, ainda abaixo de 152,45 min. Para inverter a conclusão, a busca precisaria custar ∼289× o *refit* — possível em grades grandes, mas não observado. Na regressão, a v2 (19 faixas e calibração OLS) não foi cronometrada; como exigiu mais trabalho que a v1, o custo humano real é maior que 68,22 min. A conclusão qualitativa se mantém: o custo dominante do especialista é humano, não computacional.

Ressalva de simetria. O tempo humano inclui ideação, validação clínica e iteração; o tempo de ML é apenas o ajuste final. A comparação é válida para este *dataset* e esta base de regras, não se generaliza para bases de regras muito maiores nem para *datasets* em que o treinamento é proibitivo.

(e) Qual modelo é mais interpretável? Isso importa no domínio?

O especialista é o mais interpretável: cada decisão é uma regra SE-ENTÃO com limiares clínicos auditáveis; a classificação usa 4 regras e 3 variáveis, e a regressão v2 usa 19 faixas aditivas com pontuação transparente. A árvore é a melhor opção entre os modelos que aprendem: os primeiros níveis e as regras ARV1–ARV3 são legíveis, embora

a árvore completa tenha 735–792 folhas. Random Forest e Gradient Boosting não são diretamente interpretáveis; a importância de *features* é global e não explica uma previsão individual. O GB é mais fácil de decompor (soma aditiva de árvores rasas) que a RF, mas ambos exigem explicação *post-hoc* (SHAP, *permutation importance*), não realizada.

Isso importa? Sim. Em saúde, a explicabilidade é necessária para validar decisões, detectar vieses e permitir contestação. Um modelo opaco pode ter desempenho melhor, mas precisa vir acompanhado de explicações e de governança. Para triagem automatizada de baixo risco, um *ensemble* pode ser aceitável; para decisão clínica final, especialista ou árvore são preferíveis.

(f) Qual modelo recomendar ao cliente e por quê?

Problema	**Recomendação principal**	**Alternativa**	**Justificativa**
Classificação	Gradient Boosting	Árvore (explicabilidade/*edge*) ou especialista (triagem)	Melhor média de CV (0,7126), melhor *accuracy* (0,8790), F1 de teste praticamente empatado com a RF (0,6681 vs 0,6862, dentro do ruído) e artefato ∼91× menor que a RF.
Regressão	Gradient Boosting	Especialista v2 (auditoria obrigatória)	Melhor MAE (5,9278) e R^2 (0,7745) no teste e na CV, *gap* pequeno (0,0461), inferência rápida e artefato de 157 KiB. O especialista v2 é quase tão bom (5,9941) e totalmente transparente.

Tabela 23: Recomendação final por problema.

Por que não a Random Forest? Na classificação, ela tem o melhor F1 em uma única divisão, mas a vantagem não é clara, a CV é pior que a do GB e o artefato é 69,1 MiB. Na regressão, ela *overfitta* (*gap* de MAE 1,55) e é 714× maior que o GB. O custo não se justifica.

Por que não o especialista como primeira escolha? Na classificação, ele deixa 46,13% dos casos sem resposta e tem F1 macro bem abaixo. Na regressão, ele é competitivo, mas o custo de manutenção é humano e a v2 não foi cronometrada. Ele é a melhor escolha quando a explicabilidade é requisito legal ou quando não há dados para treinar.

Implantação sugerida. Usar o GB como modelo principal, a árvore como *surrogate* interpretável para explicar casos individuais e o especialista como camada de validação clínica/*sanity check*. Monitorar *drift* e reavaliar o especialista sempre que as diretrizes clínicas mudarem.

10 Vantagens, desvantagens e limitações

10.1 Vantagens e desvantagens

Abordagem	Vantagens	Desvantagens
Sistema especialista	Totalmente auditável; não precisa de dados de treino; determinístico; artefato minúsculo (0,8–2 KiB); inferência barata; limiares clínicos justificáveis.	Elaboração manual cara (152 min na classificação); cobertura limitada (53,87%); limiares fixos não aprendem; difícil manter e escalar; conflitos exigem prioridade; não captura interações.
Árvore de decisão	Interpretável; treino e inferência muito rápidos; artefato pequeno (115–131 KiB); lida com não linearidade; boa linha de base.	Alta variância; instável a pequenas mudanças; *overfitta* sem poda (profundidade 25–35); fronteiras *axis-aligned*; pior F1 macro entre os modelos que aprendem.
Random Forest	Melhor F1 de teste na classificação; reduz variância por *bagging*; robusta; captura interações.	Artefato enorme (69,1–109,4 MiB); *overfitting* claro (*gap* 0,31/1,55); inferência mais lenta; baixa interpretabilidade; custo de memória.
Gradient Boosting	Melhor equilíbrio desempenho/custo; melhor CV nas duas tarefas; artefato compacto (157–775 KiB); inferência rápida; reduz viés sequencialmente.	Treino mais caro (30,3 s na classificação); sensível a hiperparâmetros; menos interpretável; pode *overfittar* com muitas árvores.
Especialista v2 (regressão)	Transparente; 19 faixas aditivas; MAE próximo do GB; artefato de 2 KiB; sem dependência de biblioteca de ML.	Pesos calibrados manualmente/OLS; estrutura aditiva não captura interações; manutenção manual; custo humano não totalmente cronometrado.

Tabela 24: Vantagens e desvantagens de cada abordagem.

10.2 Limitações do estudo

- **Uma única divisão treino/teste.** A CV de 5 *folds* reduz o risco de conclusões baseadas em sorte, mas os *folds* vêm do mesmo *dataset*; não há validação externa.
- **Tamanho e desbalanceamento.** A classe Low tem menos de 1% do teste; as métricas macro são sensíveis a poucos casos. O especialista não cobre 46,13% dos registros, o que limita a comparação direta.
- **Qualidade das regras.** Os limiares vêm da ADA e de estatísticas do treino; a v2 foi calibrada por OLS no treino, mas não passou por validação clínica. As regras de classificação usam apenas três variáveis e ignoram IMC e histórico familiar, que o *ensemble* considera relevantes.

- **Custo de ML subestimado.** O tempo do *notebook* 08 é de *refit*; a busca de hiperparâmetros não foi cronometrada. O custo real de construção dos modelos é maior que o reportado.
- **Cronometragem humana incompleta.** A regressão tem uma sessão (v1); faltam duas sessões e a v2 não foi cronometrada. O esforço de 68,22 min é um limite inferior.
- **Energia e CO_2 estimados.** Usam 65 W e 45,8 gCO_2/kWh, não medição de parede; servem para comparação relativa.
- **Importância de *features*.** A importância por impureza é global e favorece variáveis contínuas; não foi feita *permutation importance* nem SHAP.
- ***Hardware* único.** Os tempos dependem do i5-13420H, 7,7 GB de RAM e Windows 11; não devem ser extrapolados para outras máquinas.
- **Sem teste estatístico formal.** A comparação usa a razão entre diferença e desvio padrão da CV, não um teste pareado sobre os *folds*.

11 Considerações finais

O trabalho mostrou que a escolha do modelo depende do problema e do critério de sucesso. Na classificação, a diferença entre Random Forest e Gradient Boosting é pequena demais para justificar o custo de memória da RF; o GB é mais consistente na validação cruzada, compacto e preciso. O sistema especialista, apesar de perder em F1, tem o melhor desempenho na classe High e a vantagem de ser totalmente auditável — desde que o cliente aceite a cobertura de 53,87%.

Na regressão, o Gradient Boosting é o melhor modelo, mas o especialista v2 é surpreendentemente competitivo: com 19 faixas aditivas, um artefato de 2 KiB e calibração OLS no treino, ele fica a 0,0663 de MAE do GB e tem o menor *gap* de generalização. Isso mostra que conhecimento de domínio bem estruturado ainda é uma alternativa relevante quando a explicabilidade é requisito.

As principais dificuldades foram: representar um alvo contínuo com regras finitas (resolvida com o motor de pontuação), lidar com o desbalanceamento extremo da classe Low, garantir que o teste não participasse da elaboração das regras e comparar custos heterogêneos (tempo humano versus tempo de CPU).

Aprendizados: a validação cruzada é mais informativa que uma única divisão; o *gap* de generalização é tão importante quanto a métrica de teste; e o custo computacional, embora pequeno em termos absolutos, muda a recomendação quando o artefato é ordens de grandeza maior.

11.1 Referências

Referências

[1] AMERICAN DIABETES ASSOCIATION. Standards of Care in Diabetes. *Diabetes Care*, 2025. (Limiares diagnósticos de glicemia e HbA1c usados nas regras.)

[2] BREIMAN, L. Random Forests. *Machine Learning*, v. 45, p. 5–32, 2001.

[3] FRIEDMAN, J. H. Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001.

[4] HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning*. 2. ed. Springer, 2009.

[5] PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

[6] PROVOST, F.; FAWCETT, T. *Data Science for Business*. O'Reilly, 2013.

[7] UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE. *Avaliação Comparativa de Modelos: Sistema Especialista, Árvore de Decisão e Ensemble Learning* (main-15.pdf). DCT1401 — Inteligência Artificial, 2026.2.